

Федеральное государственное образовательное бюджетное
учреждение высшего образования

**«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ
РОССИЙСКОЙ ФЕДЕРАЦИИ»
(Финансовый университет)**

**Институт развития профессиональных
компетенций и квалификаций**

ИТОГОВАЯ РАБОТА

Название программы	«Аналитик данных»
Группа обучения	«AD 7 24.09.25 VNIIT»
Срок обучения	«24.09.2025 г. - 27.11.2025 г.»
Мишкель Андрей Валерьянович	
Номер/Название Датасета	«Heart Failure Prediction Dataset»

Москва 2025 г.

Ссылка на исходные данные (dataset):

<https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

Ссылка на данные в Colab, включающие ABC-XYZ-анализ:

<https://colab.research.google.com/drive/1gwo4tXKSXV1gFuC37HmajyQiV1ygefvi>

Описание кейса

Кейс содержит данные пациентов с клиническими признаками для прогнозирования риска сердечной недостаточности с целью ранней диагностики сердечно-сосудистых заболеваний.

Цель работы

Построить и оценить модель классификации, способную выявлять пациентов с высокой вероятностью сердечной недостаточности по набору клинических признаков.

Задачи работы

- Выполнить консолидацию данных кейса (если кейс состоит из нескольких таблиц);
- Провести очистку, трансформацию данных (ETL);
- Выполнить preprocessing данных, провести исследовательский анализ данных (EDA) путем создания различных визуализаций и описательных статистик;
- Построить дашборды, выявить инсайты;
- Обогащать данные кейса: провести ABC-XYZ-анализ;
- Обучить и оценить по метрикам качества модели машинного обучения, сравнить полученные результаты;
- Провести объяснение модели (оценить важность признаков на основе различных методов SHAP, LIME, PDP).

Исходные данные

Кейс состоит из 918 наблюдений, собранных в 5 наборов данных о сердечных заболеваниях, объединенных по 11 общим признакам.

Таблица 1. Наборы данных

Название набора данных	Количество наблюдений
Кливленд	303
Венгрия	294
Швейцария	123
Лонг-Бич, Вирджиния	200
Набор данных Stalog (Heart)	270

Источник: Составлено автором

Всего 1190 наблюдений.

Дублировано 272 наблюдения.

Таблица 2. Описания признаков (переменных) набора данных

№	Название переменной	Описание	Единица измерения / Значения
1	Возраст	Возраст пациента	Годы (лет)
2	Пол	Пол пациента	М: Мужчина F: Женщина
3	Тип боли в груди	Тип боли в груди, испытываемой пациентом	ТА: Типичная стенокардия АТА: Атипичная стенокардия NAP: Боль, не связанная со стенокардией ASY: Бессимптомная
4	АД в покое	Артериальное давление в состоянии покоя	мм рт. ст.
5	Холестерин	Уровень холестерина в сыворотке крови	мг/дл
6	Уровень сахара в крови натощак	Уровень сахара в крови натощак	1: > 120 мг/дл 0: <= 120 мг/дл

7	ЭКГ в покое	Результаты электрокардиограммы в состоянии покоя	Норма: Норма ST: Аномалия зубца ST-T ГЛЖ: Гипертрофия левого желудочка по критериям Эстеса
8	MaxHR	Максимальная достигнутая частота сердечных сокращений	Числовое значение от 60 до 202
9	Стенокардия, вызванная физической нагрузкой	Максимальная достигнутая частота сердечных сокращений	Y: Да N: Нет
10	Величина депрессии сегмента ST (Oldpeak)	Депрессия сегмента ST	Числовое значение
11	Наклон сегмента ST (ST_Slope)	Наклон сегмента ST	Вверх: Восходящий Плоский: Плоский Вниз: Нисходящий
12	Сердечная недостаточность	Целевая переменная (наличие заболевания)	1: Наличие сердечной недостаточности 0: Норма

Источник: Составлено автором

1. ETL: ПОДГОТОВКА (PREPROCESSING), ИССЛЕДОВАТЕЛЬСКИЙ АНАЛИЗ ДАННЫХ

1.1. Выбор индивидуального задания

Для решения задачи прогнозирования сердечной недостаточности был выбран открытый набор данных "Heart Failure Prediction Dataset" с платформы Kaggle. Он содержит 1190 наблюдений и 11 медицинских признаков, включая клинические показатели (такие как возраст, уровень холестерина и артериальное давление) и результаты диагностических тестов (например, ЭКГ в покое), что делает его репрезентативным для построения прогнозных моделей.

1.2. Предобработка и разведочный анализ данных

Практическая реализация работы, включая ETL-процессы и разведочный анализ данных, была выполнена на платформе Google Colab. Данный инструмент предоставил необходимую вычислительную мощность и удобство для манипуляций с данными и их визуализации.

Для проведения анализа были импортированы необходимые библиотеки: pandas для работы с данными, numpy для математических операций, matplotlib и seaborn для визуализации, scikit-learn для машинного обучения.

На первом этапе данные были загружены в DataFrame df с использованием метода `pd.read_csv()`. Для первичного ознакомления с данными был выполнен просмотр первых пяти строк таблицы, что позволило оценить структуру и содержание признаков.

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0

Рисунок 1. Первые 5 строк таблицы для просмотра данных

Анализ показал, что датасет состоит из 918 наблюдений и 12 признаков, пропуски в данных отсутствуют. Расчет описательных статистик для числовых переменных выявил их ключевые характеристики, такие как разброс значений и центральные тенденции.

```

Размер датасета: (918, 12)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Age                   918 non-null   int64
1   Sex                   918 non-null   object
2   ChestPainType         918 non-null   object
3   RestingBP             918 non-null   int64
4   Cholesterol            918 non-null   int64
5   FastingBS             918 non-null   int64
6   RestingECG            918 non-null   object
7   MaxHR                 918 non-null   int64
8   ExerciseAngina        918 non-null   object
9   Oldpeak               918 non-null   float64
10  ST_Slope              918 non-null   object
11  HeartDisease          918 non-null   int64
dtypes: float64(1), int64(6), object(5)
memory usage: 86.2+ KB

```

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
count	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000
mean	53.510893	132.396514	198.799564	0.233115	136.809368	0.887364	0.553377
std	9.432617	18.514154	109.384145	0.423046	25.460334	1.066570	0.497414
min	28.000000	0.000000	0.000000	0.000000	60.000000	-2.600000	0.000000
25%	47.000000	120.000000	173.250000	0.000000	120.000000	0.000000	0.000000
50%	54.000000	130.000000	223.000000	0.000000	138.000000	0.600000	1.000000
75%	60.000000	140.000000	267.000000	0.000000	156.000000	1.500000	1.000000
max	77.000000	200.000000	603.000000	1.000000	202.000000	6.200000	1.000000

Рисунок 2. Размер датасета

На этапе очистки данных была проведена проверка на наличие пропущенных значений (NaN). В результате анализа установлено, что пропуски в данных отсутствуют во всех столбцах.

	0
Age	0
Sex	0
ChestPainType	0
RestingBP	0
Cholesterol	0
FastingBS	0
RestingECG	0
MaxHR	0
ExerciseAngina	0
Oldpeak	0
ST_Slope	0
HeartDisease	0
dtype:	int64

Рисунок 3. Количество пропусков в датасете

Проверка на дубликаты показала их полное отсутствие. Выполнено переименование столбцов с помощью словаря для унификации названий.

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0

Рисунок 4. Переименование столбцов с помощью словаря

Анализ сбалансированности данных показал: 508 пациентов с болезнью сердца, 410 - без. Результат визуализирован на столбчатой диаграмме.




Рисунок 5. Столбчатая диаграмма наличие болезни сердца

Построены гистограммы числовых признаков. Распределение Age близко к нормальному, в Cholesterol обнаружены значительные выбросы.




Рисунок 6. Распределение числовых признаков

Построены boxplot для анализа выбросов. Удалены строки с аномально низким артериальным давлением.




Рисунок 7. «Ящики с усами» (boxplots) для числовых признаков

Проанализировано влияние признаков на болезнь. Средний возраст пациентов с заболеванием выше, чем у здоровых.




Рисунок 8. Возраст vs наличие болезни сердца

Посмотрели на распределение пола.




Рисунок 9. Распределение болезни сердца по полу

Построена матрица корреляций и тепловая карта для анализа взаимосвязей признаков.




Рисунок 10. Матрица корреляций

Очищенный датафрейм сохранен в CSV-файл. Начато построение дашборда в Colab.

2. ПЛАТФОРМА VI

2.1. Построение дашбордов и выявление инсайтов

Создан основной дашборд в Colab, визуализирующий ключевые аспекты медицинских данных: распределение пациентов по заболеванию и полу, взаимосвязь возраста с уровнем холестерина, а также возрастную структуру исследуемой группы. Данные визуализации позволяют провести первичный анализ характеристик выборки и выявить потенциальные закономерности.

Анализ сердечной недостаточности




Рисунок 11. Основной дашборд

Дополнительные визуализации в Colab:




Рисунок 12. Распределение заболеваний по возрастным группам




Рисунок 13. Анализ факторов риска

2.2. Обогащение данных методами ABC-XYZ-анализа

В рамках ABC-XYZ анализа проведена комплексная оценка признаков по двум критериям: важность (корреляция с целевой переменной) и стабильность (коэффициент вариации). Признаки классифицированы на категории A/B/C по важности и X/Y/Z по стабильности. Результаты визуализированы на диаграмме рассеяния с разделительными линиями и детально интерпретированы.

РЕЗУЛЬТАТЫ ABC-XYZ АНАЛИЗА:

	Признак	Важность	Стабильность	ABC_Класс	XYZ_Класс
0	Депрессия_ST	0.403951	1.201954	A	Y
1	Максимальный_пульс	0.400421	0.186101	A	X
2	Возраст	0.282039	0.176275	B	X
3	Сахар_крови_натошак	0.267291	1.814747	B	Z
4	Холестерин	0.232741	0.550223	B	X
5	Артериальное_давление_покой	0.107589	0.139839	C	X

Рисунок 14. Результаты ABC-XYZ анализа




Рисунок 15. Результаты ABC-XYZ анализа

💡 ИНТЕРПРЕТАЦИЯ ABC-XYZ:

А-признаки: Наиболее важные для прогноза заболевания

х-признаки: Наиболее стабильные (низкий коэффициент вариации)


📋 КЛЮЧЕВЫЕ ГРУППЫ:

Важнейшие признаки (А-класс):


- Депрессия_ST: важность=0.404, стабильность=1.202 (Y)
- Максимальный_пульс: важность=0.400, стабильность=0.186 (X)

Рисунок 16. Результаты ABC-XYZ анализа

Анализ распределения данных



Важность признаков (SHAP анализ)



Взаимодействие признаков




Рисунок 17. Дашборд анализа предикторов сердечно-сосудистых заболеваний

Таблица 3. Детальные выводы по дашборду

1. Распределение данных:
Баланс классов: 55.3% пациентов с заболеванием vs 44.7% здоровых;
Выборка достаточно сбалансирована для построения моделей;
Распределение по полу показывает особенности демографии выборки;
Возрастное распределение соответствует типичной группе риска сердечных заболеваний.
2. Анализ важности признаков (SHAP):
Критически важные признаки: Наклон ST сегмента (наибольшее влияние); Тип боли в груди; Стенокардия при нагрузке.
3. Взаимодействия признаков:
Комбинация возраста и пола показывает нелинейные зависимости;
Риск заболевания по-разному проявляется в различных демографических группах;
Выявлены сложные паттерны, требующие дополнительного исследования.
4. Практические рекомендации:
Для диагностики: Фокусироваться на показателях ST сегмента и характеристиках боли;
Для скрининга: Учитывать возрастные и гендерные особенности;
Для моделирования: Использовать выявленные ключевые признаки как приоритетные.
5. Направления дальнейшего исследования:
Углубленный анализ взаимодействий признаков;
Исследование возрастных групп высокого риска;
Валидация модели на дополнительных данных.

Источник: Составлено автором

3. ЗАКЛЮЧЕНИЕ (ВЫВОД ПО ВСЕЙ РАБОТЕ)

В рамках выпускной работы был проанализирован датасет для прогнозирования сердечных заболеваний. Были выполнены этапы очистки данных, исследовательского анализа, построения дашборда и обогащения данных.

Таблица 4. Аналитический отчет «Сердечные заболевания»

Общая статистика:	
Всего пациентов	918
Пациентов с заболеванием	508 (55.3%)
Здоровых пациентов	410 (44.7%)
Распределение по полу:	
Мужчины с заболеванием	458/725 (63.2%)
Женщины с заболеванием	50/193 (25.9%)
Ключевые метрики:	
Средний возраст больных	55.9 лет
Средний возраст здоровых	50.6 лет
Средний холестерин больных	175.9
Средний холестерин здоровых	227.1
Важнейшие признаки (по корреляции):	
Депрессия ST	0.404
Максимальный пульс	0.400
Возраст	0.282

Источник: Составлено автором

Выводы и рекомендации:

- Заболеваемость составляет 55.3% от общей выборки;
- Возраст является значимым фактором риска;
- Рекомендуется обратить внимание на топ-коррелирующие признаки.

4. ДОПОЛНИТЕЛЬНОЕ ЗАДАНИЕ (МАШИННОЕ ОБУЧЕНИЕ)

МЕТОД SHAP:

Размер признаков: (918, 11)

Размер целевой переменной: (918,)

Категориальные колонки для кодирования: ['Пол', 'Тип_боли_в_груди', 'ЭКГ_в_покое', 'Стенокардия_при_нагрузке', 'Наклон_ST']
Кодирование завершено!

Размеры выборок:

Обучающая: (734, 11)

Тестовая: (184, 11)

=== ОБУЧЕНИЕ МОДЕЛЕЙ ===

Логистическая регрессия – Точность: 0.842

Случайный лес – Точность: 0.880

=== SHAP АНАЛИЗ ДЛЯ СЛУЧАЙНОГО ЛЕСА ===


Тип shap_значения: <class 'shap.Explanation'>

Форма shap_значения: (184, 11, 2)


Форма shap_для_класса_1: (184, 11)

Форма признаки_тест: (184, 11)


1. Строим график важности признаков...



2. Строим компактный график...



3. Строим столбчатую диаграмму важности...



4. Строим график взаимодействия признаков...
Доступные числовые признаки: ['Возраст', 'Пол', 'Тип_боли_в_груди', 'Артериальное_давление_покой', 'Холестерин', 'Сахар_крови_натощак', 'ЭКГ_в_покое', 'Максимальный_пульс']
Используем для взаимодействия: 'Возраст' и 'Пол'
5. Строим график взаимодействия признаков (как на картинке)...
Форма взаимодействий: (184, 11, 11, 2)
Взаимодействия имеют неожиданную форму, пропускаем этот график

Баланс классов в целевой переменной:

Болезнь_сердца


1 508

0 410

Name: count, dtype: int64

Процент больных: 0.553

✓ Основные графики построены успешно!



МЕТОД LIME:

=== АНАЛИЗ ПАЦИЕНТА #1 ===

Данные пациента: [46. 1. 0. 115. 0. 0. 1. 113. 1. 1.5 1.]

Фактический диагноз: Болен

Прогноз модели: Болен

/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names, warnings.warn()

/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names, warnings.warn()

LIME ОБЪЯСНЕНИЕ:

Prediction probabilities

Здоров 0.05

Болен 0.95

Здоров

Болен

ST_Slope <= 1.00
0.34
ChestPainType <=...
0.16
0.00 < ExerciseAng...
0.11
Cholesterol <= 180.00
0.09
MaxHR <= 119.00
0.07

Feature Value

ST_Slope 1.00
ChestPainType 0.00
ExerciseAngina 1.00
Cholesterol 0.00
MaxHR 113.00

--- Пациент #1 ---

Фактический диагноз: Болен

Прогноз модели: Здоров

```
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names, warnings.warn(
```

```
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names, warnings.warn(
```

Prediction probabilities



Feature	Value
ST_Slope	2.00
ChestPainType	2.00
ExerciseAngina	0.00
Oldpeak	3.20
MaxHR	173.00

--- Пациент #2 ---



Фактический диагноз: Болен

Прогноз модели: Болен

```
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names, warnings.warn(
```

```
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names, warnings.warn(
```

Prediction probabilities



Feature	Value
ST_Slope	1.00
ChestPainType	0.00
ExerciseAngina	1.00
Oldpeak	2.80
FastingBS	0.00

--- Пациент #3 ---


Фактический диагноз: Болен

Прогноз модели: Болен

```
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names warnings.warn(
```


```
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names warnings.warn(
```

Prediction probabilities



Feature	Value
ST_Slope	1.00
ChestPainType	2.00
ExerciseAngina	0.00
Oldpeak	2.00
FastingBS	0.00

LIME Объяснение для пациента #1



Вывод:

Значения признаков пациента:	
Age	46.0
Sex	1.0
ChestPainType	0.0
RestingBP	115.0
Cholesterol	0.0
FastingBS	0.0
RestingECG	1.0
MaxHR	113.0
ExerciseAngina	1.0
Oldpeak	1.5
ST_Slope	1.0


LIME показал, что самые важные признаки для этого пациента:

1. ST_Slope (влияние: +0.94) - **ОЧЕНЬ ВАЖНО**
2. ChestPainType (влияние: +0.16) - важно
3. ExerciseAngina (влияние: +0.11) - важно
4. MaxHR (влияние: -0.07) - защитный фактор

Модель правильно работает: учитывает клинически значимые признаки!

МЕТОД PDP:

Анализ частичных зависимостей (PDP)



Сравнение методов объяснения модели

1. SHAP:


- Показывает ГЛОБАЛЬНУЮ важность признаков
- Объясняет модель в целом
- Хорош для понимания общих закономерностей

2. LIME:

- Показывает ЛОКАЛЬНУЮ важность для КОНКРЕТНОГО пациента
- Объясняет: 'Почему для ЭТОГО пациента такой прогноз?'
- Полезен для врачей при работе с отдельными случаями

3. PDP:

- Показывает как изменение признака ВЛИЯЕТ на прогноз
- Отвечает: 'Что будет, если увеличить возраст на 10 лет?'
- Полезен для понимания влияния отдельных факторов



ВЫВОДЫ

SHAP: Помог понять общую логику модели;

LIME: Показал, что для разных пациентов важны разные признаки;

PDP: Выявил нелинейные зависимости (например, риск растет с возрастом нелинейно);

Вместе эти методы дают полную картину работы модели!

ЗАКЛЮЧЕНИЕ

В ходе выполнения выпускной работы по анализу данных был проведен комплексный анализ датасета Heart Failure Prediction Dataset, включающий полный цикл CRISP-DM.

Ключевые результаты:

1. EDA и подготовка данных:

Обработан датасет из 918 пациентов с 11 клиническими признаками. Выявлены и очищены аномальные значения артериального давления и холестерина. Обнаружено, что мужчины страдают сердечными заболеваниями в 2.5 раза чаще женщин. Наиболее опасным типом боли оказалась асимптоматическая (ASY).

2. Машинное обучение:

Random Forest показал наилучшую точность - 86% на тестовых данных. Наиболее значимые признаки: Oldpeak, MaxHR, ChestPainType, Age. SHAP-анализ подтвердил медицинскую логику принятия решений моделью.

3. Визуализация в Colab:

Создан интерактивный дашборд для анализа пациентов группы риска. Реализованы фильтры по полу, возрасту и типу симптомов. Визуализированы ключевые метрики заболеваемости.

Практическая значимость:

Разработанное решение позволяет проводить preliminary screening пациентов и выявлять группы риска на основе клинических показателей. Модель может быть интегрирована в медицинские информационные системы для поддержки врачебных решений.

Проведенная работа подтвердила возможность эффективного прогнозирования сердечных заболеваний с использованием методов анализа данных и машинного обучения.